

Exercices de Statistiques
Université de Lorraine

Estimation et théorie des tests

Clément Dell'Aiera

1 Principe de Neyman : décision à 2 points

1. Soit f la densité d'une loi de probabilité sur \mathbb{R} , et \mathcal{E} l'expérience statistique engendré par un n -échantillon de loi $p_\theta(x) = f(x - \theta)$. On suppose que $\Theta = \{0, \theta_0\}$ avec $\theta_0 \neq 0$. On veut tester $H_0|\theta = 0$ contre $H_1|\theta = \theta_0$.
 - (a) Décrire l'expérience statistique et donner la vraisemblance du modèle.
 - (b) Donner la zone de rejet du test de Neyman-Pearson de niveau α associé à H_0 et H_1 .
2. L'expérimentateur observe une seule réalisation d'une v.a. X de loi de Poisson de paramètre $\theta > 0$. On veut tester $H_0|\theta = \theta_0$ contre $H_1|\theta = \theta_1$, où $\theta_0 \neq \theta_1$.
 - (a) Donner la zone de rejet du test de Neyman-Pearson de niveau α associé.
 - (b) Sachant que $\mathbb{P}_{\theta_0}(X > 9) = 0.032$ et $\mathbb{P}_{\theta_1}(X > 8) = 0.068$, donner une zone de rejet explicite pour $\alpha = 0.05 = 5\%$. Le test est-il optimal ?

2 Neyman-Pearson : familles à rapport de vraisemblance monotone

1. Soit \mathcal{E} l'expérience statistique engendrée par un n -échantillon de loi normale $\mathcal{N}(\theta, \sigma^2)$, où σ^2 est connu, et $\theta \in \Theta = \mathbb{R}$. On souhaite tester $H_0|\theta = \theta_0$ contre $H_1|\theta = \theta_1$, où $\theta_0 < \theta_1$.
 - (a) Décrire le modèle ainsi que la vraisemblance. On choisira la mesure de Lebesgue comme mesure dominante.
 - (b) Calculer le rapport de vraisemblance

$$\frac{f(\theta_1, Z)}{f(\theta_0, Z)}.$$

- (c) Donner la zone de rejet pour le test de Neyman-Pearson associé.
2. Pour la même expérience statistique, on a un test optimal (uniformément plus puissant) de H_0 contre H_1 donné par la région de rejet

$$\mathcal{R} = \{\bar{X}_n > c\}$$

où c est solution de $\mathbb{P}_{\theta_0}(\bar{X}_n > c) = \alpha$.

- (a) Calculer explicitement la valeur de la constante $c = c(\theta_0, \alpha)$.
- (b) Calculer la puissance de ce test.

3 Exercice

L'expérimentateur observe 2 échantillons indépendants X_1, \dots, X_n et Y_1, \dots, Y_m de tailles distinctes $n \neq m$, de lois respectives $\mathcal{N}(\mu_1, \sigma_1^2)$ et $\mathcal{N}(\mu_2, \sigma_2^2)$. Il souhaite tester

$$H_0 : \mu_1 = \mu_2 \quad \text{contre} \quad H_1 : \mu_1 \neq \mu_2.$$

Si $s_{n,1}^2 = \frac{1}{n} \sum_{j=1}^n (X_j - \bar{X}_n)^2$ et $s_{m,2}^2 = \frac{1}{m} \sum_{j=1}^m (Y_j - \bar{Y}_m)^2$, construire un test basé sur la statistique

$$T_{n,m} = \frac{\bar{X}_n - \bar{Y}_m}{\sqrt{s_{n,1}^2 + s_{m,2}^2}}$$

et étudier sa consistance.

4 Tests du χ^2

On considère une variable qualitative X , à valeur dans un ensemble fini $E = \{1, \dots, d\}$. Les lois de probabilité de telles v.a. sont entièrement décrites par le vecteur de probabilité $(p_1, \dots, p_d)^T$, où $p_j = \mathbb{P}(X = j)$. On confondra donc les lois de probabilités de E avec

$$\mathfrak{M}_d = \{p = (p_1, \dots, p_d)^T : 0 \leq p_j \leq 1 \text{ et } \sum p_j = 1\}.$$

1. **Test d'adéquation du χ^2 .** On observe un n -échantillon de loi p et l'on souhaite tester $p = q$ contre $p \neq q$ où $q \in \mathfrak{M}_d$ est une loi fixée.
 - (a) Décrire le modèle statistique.
 - (b) On définit les fréquences empiriques

$$\hat{p}_{n,l} = \frac{1}{n} \sum_{j=1}^n 1_{X_j=l} \quad \text{pour } l = 1, \dots, d.$$

Donner la limite du vecteur $\hat{p}_n = (\hat{p}_{n,l})_{l=1,d}^T$ pour la topologie de la convergence en probabilité sous \mathbb{P}_p .

- (c) On définit

$$U_n(p) = \sqrt{n} \left(\frac{\hat{p}_{n,l} - p_l}{\sqrt{p_l}} \right)_{l=1,d}^T.$$

Donner la limite en loi de chaque composante de $U_n(p)$ sous \mathbb{P}_p . Que peut-on dire a priori de la limite en loi de $U_n(p)$? Pourquoi?

- (d) On définit

$$Y_l^j = \frac{1}{\sqrt{p_l}} (1_{X_j=l} - p_l).$$

Si Y_j désigne le vecteur (Y_1^j, \dots, Y_d^j) , montrer que $\frac{1}{\sqrt{n}} \sum Y_j = U_n(p)$.

- (e) Calculer $E[Y_l^j]$, et $E[Y_l^j Y_{l'}^j]$. Que valent les composantes de la matrice $V(p) = I_d - \sqrt{p} \sqrt{p}^T$, où $\sqrt{p} = (\sqrt{p_1}, \dots, \sqrt{p_d})^T$?
- (f) En déduire la limite en loi sous \mathbb{P}_p de $U_n(p)$ et de $\|U_n(p)\|^2$, le carré de sa norme euclidienne.
- (g) Soient $p, q \in \mathfrak{M}_d$ tels que les coefficients de q soient tous non nuls. On définit :

$$\chi^2(p, q) = \sum_{l=1}^d \frac{(p_l - q_l)^2}{q_l}.$$

Cette quantité est appelée "distance du χ^2 " bien que ce ne soit pas une distance ! Toutefois, $\chi^2(p, q) = 0$ ssi $p = q$.

Montrer que $n\chi^2(\hat{p}_n, p) = \|U_n(p)\|^2$.

- (h) On définit, pour $\alpha \in (0, 1)$, la zone de rejet

$$\mathcal{R}_{n,\alpha} = \{n\chi^2(\hat{p}_n, p) \geq q_{1-\alpha, d-1}^{\chi^2}\},$$

où $q_{1-\alpha, d-1}^{\chi^2}$ est le quantile d'ordre $1 - \alpha$ de la loi du χ^2 à $d - 1$ degrés de liberté.

Montrer que le test associé est asymptotiquement de niveau α et est asymptotiquement consistant.